Projekt 1

Karolina Gralak, Wiktor Chmiel
Interpretowalność i wyjaśnialność uczenia maszynowego

8 grudnia 2025

Spis treści

1 Cel projektu **3**

2 Przygotowanie danych i EDA **3**
2.1 Kontrola jakośći danych . . . 3
2.2 Identyfikacja i obsługa braków danych . . . 4
2.3 Usuwanie zbędnych kolumn (Cech) . . . 4
2.4 Przygotowanie cech i pipeline przetwarzania danych . . . 5

3 Podział danych **6**

4 Model interpretowalny **6**
4.1 Wybór modelu . . . 6
4.2 Dobór hiperparametrów (Grid Search) . . . 6
4.3 Wyniki wyszukiwania . . . 7

5 Model typu black-box **7**
5.1 Konfiguracja modelu . . . 7
5.2 Dobór hiperparametrów . . . 8
5.3 Wybór najlepszego modelu . . . 8

6 Metryki **9**
6.1 Porównanie jakości modeli . . . 9

7 Interpretowalność modeli **10**
7.1 Interpretowalność globalna modelu regresji logistycznej . . . 11
7.2 Znaki i wielkości współczynników . . . 11
7.3 Profilowanie cech: PDP i ICE . . . 12
7.4 Interpretowalność lokalna modelu regresji logistycznej . . . 12
7.5 Interpretowalność globalna modelu XGBoost . . . 13
7.6 Ważność cech: SHAP summary . . . 13
7.7 Krzywe zależności SHAP . . . 14
7.8 Interpretowalność lokalna modelu XGBoost . . . 15
7.9 Porównanie interpretowalności modeli . . . 16

8 Kalibracja **17**
8.1 Kalibracja prawdopodobieństw dla modelu XGBoost 17
8.2 Kalibracja prawdopodobieństw dla modelu regresji logistycznej 20

9 Progi decyzyjne i mapowanie PD na ratingi **21**
9.1 Dobór progu decyzyjnego na podstawie funkcji kosztu 21
9.2 Macierz pomyłek i metryki dla optymalnego progu 22
9.3 Mapowanie skalibrowanej PD na ratingi 22
9.4 Interpretacja biznesowa progu i ratingów 23

10 Wnioski i podsumowanie **24**

1 Cel projektu

Celem projektu było zaprojektowanie, zbudowanie i ocena dwóch modeli predykcyjnych oceniających ryzyko na podstawie danych finansowych.

2 Przygotowanie danych i EDA

2.1 Kontrola jakośći danych

Pierwszym krokiem była ocena jakości danych pod kątem kompletności, spójności oraz potencjalnych anomalii. Zestaw zmiennych obejmuje wskaźniki finansowe, operacyjne oraz cechy opisujące klientów, typowe dla modeli ryzyka kredytowego. Zbadano wielkość procentową klasy 1 w zmiennej celu- zyniosła ona 14,83%.

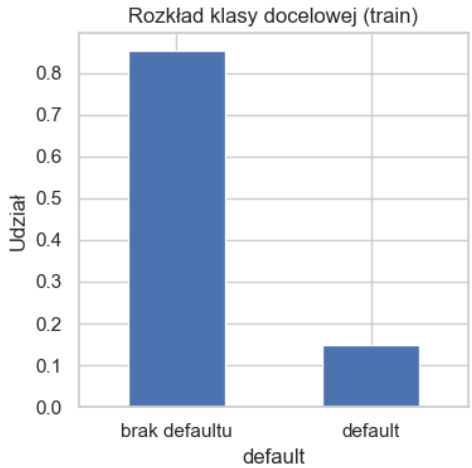

Poniżej przedstawiono histogramy wybranych kilku cech:

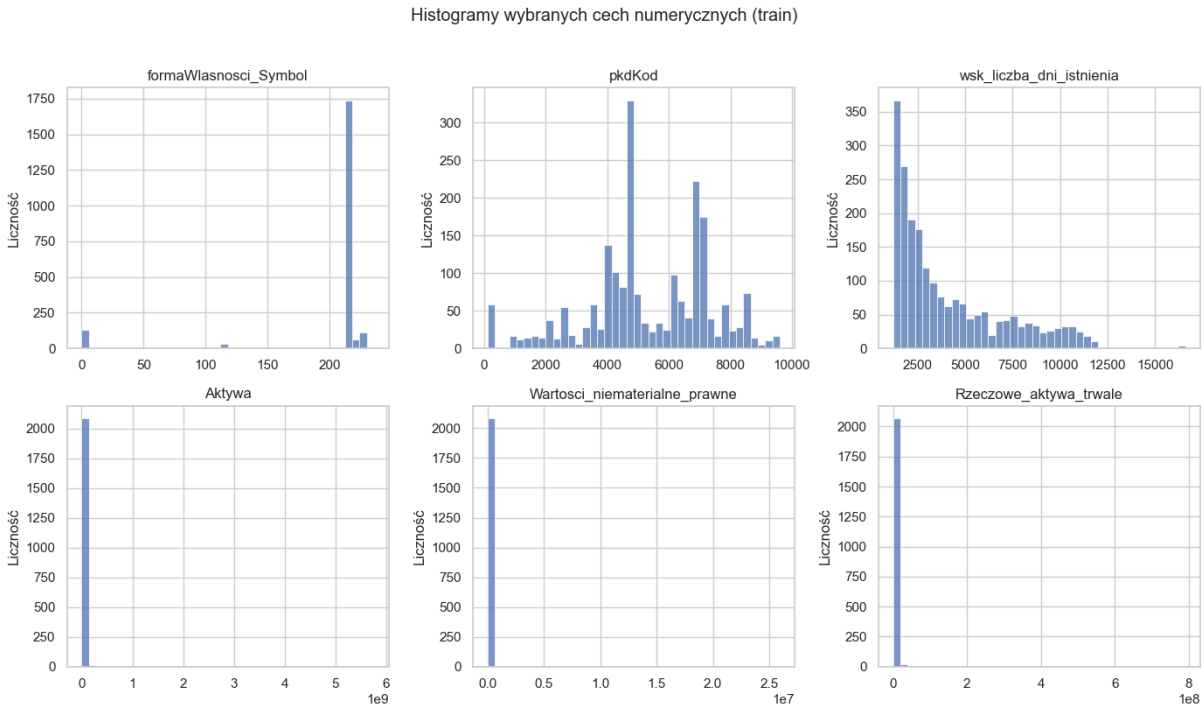

Oraz ich jądrowe estymatory gęstości z podziałem na przyneleżność do klasy $deafult$:

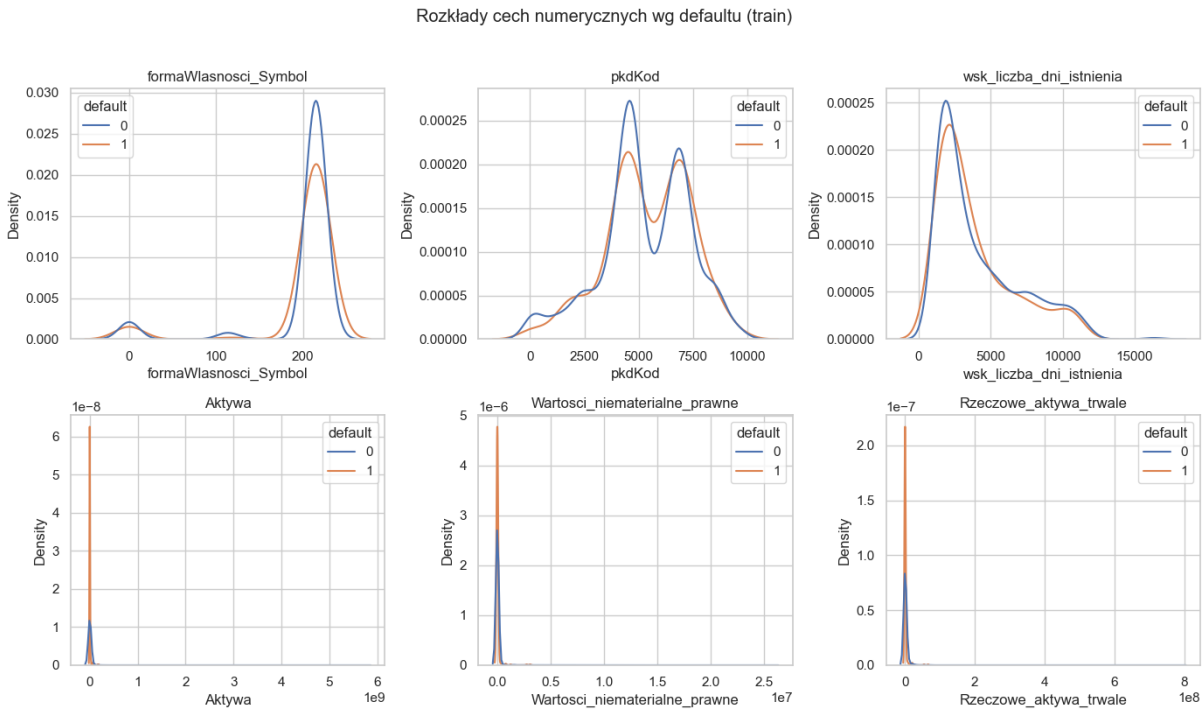

2.2 Identyfikacja i obsługa braków danych

W tym miejscu naniesione zostały poprawki na zbiór danych: usunięto puste stringi, wartości whitespace i inne wartości niepoprawne (takie jak inf, -inf). Wszystkie je zamieniono na Nan, aby mogły zostać prawidłowo imputowane.

2.3 Usuwanie zbędnych kolumn (Cech)

Zostały policzone odsetki braków dla każdej zmiennej; zmienne z >85% braków zostały usunięte, jako że nie niosły wartości informacyjnej.
Zbadano również istnienie kolumny zawierającej tylko jedną wartość, ale nie zaobserowowano takiej.
Dodatkowo aby poprawić stabilność modeli oraz ograniczyć problem współliniowości (kolinearności), wykonano analizę korelacji pomiędzy zmiennymi numerycznymi. Obliczono macierz korelacji dla wszystkich cech liczbowych w zbiorze treningowym, a następnie dla każdej pary cech sprawdzono, czy ich bezwzględna korelacja przekracza ustalony próg 0.8. Poniższy wykres przedstawia macierz kowariancji dla top 15 cech numerycznych

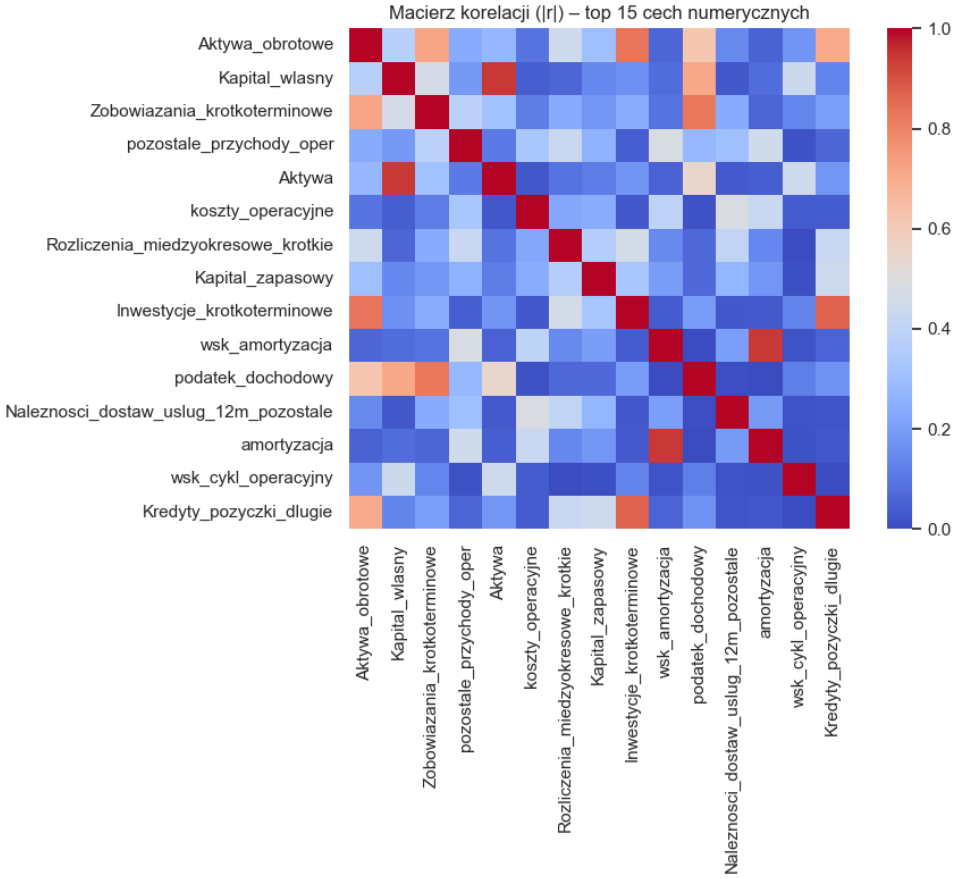

2.4 Przygotowanie cech i pipeline przetwarzania danych

W celu zapewnienia spójnego i kontrolowanego przetwarzania wszystkich predyktorów zbudowano `pipeline` obejmujący oddzielny proces dla zmiennych liczbowych oraz kategorycznych.

Pipeline dla zmiennych liczbowych

Pipeline numeryczny (`num_transformer`) składa się z trzech kroków:

1. Imputacja braków (medianą) z dodaniem wskaźników. Braki danych w zmiennych liczbowych uzupełniono medianą, stosując `SimpleImputer`. Włączono opcję `add_indicator=True`, co powoduje utworzenie dodatkowych cech binarnych informujących, czy dana obserwacja pierwotnie zawierała wartość `NaN`. Informacja ta często niesie wartość predykcyjną.

2. Przycinanie wartości odstających (outlier capping). W kolejnym kroku zastosowano autorski transformer `OptimizedOutlierCapper`, oparty na zmodyfikowanym przedziale międzykwartylowym (IQR)- Dla każdej zmiennej obliczane są kwantyle $q_{\min}$ i $q_{\max}$, a następnie:

$$\mathrm{IQR} = Q_{q_{\max}} - Q_{q_{\min}},$$

$$\mathrm{lower} = Q_{q_{\min}} - \mathrm{factor} \cdot \mathrm{IQR}, \qquad \mathrm{upper} = Q_{q_{\max}} + \mathrm{factor} \cdot \mathrm{IQR}.$$

Wszystkie wartości poniżej `lower` oraz powyżej `upper` są przycinane do granic przedziału.

3. Standaryzacja. Zastosowano `StandardScaler` z parametrem `with_mean=False`, co skaluje cechy poprzez dzielenie przez odchylenie standardowe (bez odejmowania średniej).

Pipeline dla zmiennych kategorycznych

Pipeline dla zmiennych kategorycznych (`cat_transformer`) składa się z:

1. Imputacji braków. Brakujące wartości zastąpiono etykietą `"missing"` przy pomocy `SimpleImputer`, co umożliwia jawne zachowanie informacji o braku.

2. One-hot encodingu. Do zakodowania zmiennych kategorycznych wykorzystano `OneHotEncoder` z parametrem `handle_unknown=ignore`, który eliminuje ryzyko błędów w przypadku pojawienia się nowej kategorii w zbiorze testowym.

Scalenie transformacji: ColumnTransformer

Oba pipeline'y zostały połączone przy użyciu `ColumnTransformer`, który automatycznie rozdziela cechy na numeryczne i kategoryczne.1

3 Podział danych

Wydzielono 30% obserwacji jako zbiór testowy, który służy do końcowej oceny jakości modeli. Pozostałe 70% danych tworzy zbiór treningowo-walidacyjny wykorzystywany podczas uczenia modeli i doboru hiperparametrów. Podział wykonano z parametrami: stratify = y, dzięki czemu proporcja klasy pozytywnej (default) została zachowana w obu zbiorach, co jest kluczowe przy pracy z danymi niebalansowymi i random_state = 42, zapewniającym replikowalność wyników.

4 Model interpretowalny

4.1 Wybór modelu

Jako model interpretowalny zastosowano **regresję logistyczną**, która jest standardem w modelowaniu ryzyka kredytowego ze względu na swoją przejrzystość, interpretowalność log-odds oraz stabilność działania.
Dzięki zastosowaniu `Pipeline` i `ColumnTransformer` wszystkie transformacje danych (imputacja, capping, kodowanie kategorii, skalowanie) wykonywane są wewnątrz procesu walidacji krzyżowej, co eliminuje ryzyko wycieku informacji i zapewnia rzetelność uzyskanych wyników.

4.2 Dobór hiperparametrów (Grid Search)

Przeprowadzono przeszukiwanie przestrzeni hiperparametrów przy użyciu metody **GridSearchCV** z pięciokrotną walidacją krzyżową (StratifiedKFold). Jako metrykę optymalizacyjną zastosowano pole pod krzywą ROC (AUC).
Sprawdzane były następujące hiperparametry:

1. Rodzaj regularyzacji: L1, L2, ElasticNet

2. Wartość parametru $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$
3. (dla ElasticNet) Wartość parametru $l1_ratio \in \{0.1, 0.5, 0.9\}$

Tak zaprojektowany grid umożliwia kompleksową ocenę, czy model preferuje rzadszą reprezentację (L1), bardziej gładką i stabilną regularyzację (L2), czy mieszankę obydwu (ElasticNet).

4.3 Wyniki wyszukiwania

GridSearchCV został uruchomiony równolegle (`n_jobs=-1`) oraz z włączonym monitorowaniem postępu (`verbose=1`). Po zakończeniu procesu uzyskano:

- zestaw najlepszych hiperparametrów: C = 0.01, regularyzację- L2,
- najlepszy wynik AUC na walidacji krzyżowej- 0.6800
- dopasowany model gotowy do dalszej interpretacji i kalibracji probabilistycznej.

5 Model typu black-box

Jako model typu black-box wybrano model XGBoost, cechujący się wysoką jakością predykcji, który jest jednym z najskuteczniejszych modeli drzewiastych w zastosowaniach scoringowych.

5.1 Konfiguracja modelu

Wstępna konfiguracja klasyfikatora XGBoost obejmowała m.in.:

- `objective = "binary:logistic"` - klasyfikacja binarna z wyjściem probabilistycznym,
- `eval_metric = "logloss"` - stabilna i zalecana metryka dla danych niezbalansowanych,
- `tree_method = "hist"` - szybka wersja algorytmu do dużych zbiorów,
- `n_estimators = 300` - liczba drzew (wartość bazowa),
- `learning_rate = 0.1` - tempo uczenia boosterów,
- `max_depth = 4` - głębokość drzew (kontrola złożoności),
- `subsample = 0.8` i `colsample_bytree = 0.8` – losowe podpróbkowanie obserwacji i cech w każdym drzewie,
- `reg_lambda` i `reg_alpha` -regularyzacja L2 i L1 ograniczająca przeuczenie,
- `random_state = 42` - pełna replikowalność,
- `n_jobs = -1` - trenowanie równoległe.

Tak skonstruowany model stanowił punkt wyjścia do strojenia hiperparametrów.

5.2 Dobór hiperparametrów

W celu identyfikacji najlepszego modelu przeprowadzono **RandomizedSearchCV** z pięciokrotną walidacją krzyżową, optymalizując wynik AUC. Losowe przeszukiwanie przestrzeni parametrów jest szczególnie efektywne w XGBoost, ponieważ wiele hiperparametrów ma nieliniowy wpływ na wynik, a pełny grid search byłby zbyt kosztowny obliczeniowo.

Przeszukiwana przestrzeń obejmowała:

1. liczbę drzew: $n_estimators \in \{200, 300, 400, 600\}$,
2. głębokość drzew: $max_depth \in \{3, 4, 5, 6\}$,
3. tempo uczenia: $learning_rate \in \{0.03, 0.05, 0.1, 0.2\}$,
4. frakcję próbek: $subsample \in \{0.6, 0.8, 1.0\}$,
5. frakcję cech: $colsample_bytree \in \{0.6, 0.8, 1.0\}$,
6. minimalną wagę liścia: $min_child_weight \in \{1, 3, 5, 10\}$,
7. parametr czyszczenia gałęzi: $gamma \in \{0, 0.1, 0.3, 1.0\}$,
8. regularyzację:

$$\texttt{reg_lambda} \in \{0.1, 1.0, 5.0, 10.0\}, \quad \texttt{reg_alpha} \in \{0.0, 0.1, 1.0\}.$$

5.3 Wybór najlepszego modelu

Po zakończeniu losowego przeszukiwania uzyskano:

1. najlepszy zestaw hiperparametrów (zgodny z maksymalnym AUC w CV):
   - liczbę drzew: n_estimators = 300 ,
   - głębokość drzew: max_depth = 3,
   - tempo uczenia: learning_rate = 0.03,
   - frakcję próbek: subsample = 0.6,
   - frakcję cech: colsample_bytree = 0.8,
   - minimalną wagę liścia: min_child_weight = 5,
   - parametr czyszczenia gałęzi: gamma = 0,
   - regularyzację: reg_lambda = 5.0, reg_alpha = 0
2. najlepszy pełny pipeline
3. Najlepszy wynik AUC na kroswalidacji krzyzowej AUC = 0.7085
4. dopasowany model XGBoost, który został następnie wykorzystany do analizy SHAP i wyjaśnialności lokalnej/globalnej.

6 Metryki

W tej części zbadaliśmy podstawowe metryki dla powstałych modeli.

6.1 Porównanie jakości modeli

Po dopasowaniu modeli regresji logistycznej oraz XGBoost dokonano ich oceny na zbiorze testowym $(X_{\text{test}}, y_{\text{test}})$, który nie był używany ani w procesie uczenia, ani w strojenia hiperparametrów. Dla każdego modelu obliczono następujące miary jakości oparte na predykowanych prawdopodobieństwach $\hat{p}_i = P(Y_i = 1 \mid X_i)$:

- **AUC ROC** (Area Under ROC Curve) - pole pod krzywą ROC, interpretowane jako prawdopodobieństwo, że model przypisze wyższe prawdopodobieństwo zdarzenia ryzyka obserwacji pozytywnej niż negatywnej:
$$\text{AUC} = P\big(\hat{p}^+ > \hat{p}^-\big).$$
- **Współczynnik Giniego** - zdefiniowany jako
$$G = 2 \cdot \text{AUC} - 1,$$
będący przeskalowaną wersją AUC; $G = 0$ odpowiada modelowi losowemu, $G = 1$ modelowi idealnemu.
- **Statystyka KS (Kolmogorov–Smirnov)** - maksymalna różnica między dystrybuantami predykowanych prawdopodobieństw dla klas $Y = 1$ oraz $Y = 0$:
$$\text{KS} = \max_{t \in [0,1]} \big(\text{TPR}(t) - \text{FPR}(t)\big),$$
gdzie $\text{TPR}(t)$ i $\text{FPR}(t)$ oznaczają odpowiednio czułość i odsetek fałszywych alarmów przy progu t.
- **PR-AUC** (pole pod krzywą precision-recall) - miara jakości rozróżniania klas przy silnej nierównowadze klas, liczona jako pole pod krzywą zależności *precision* od *recall*.
- **Log-loss** (logarytmiczna funkcja straty) - średnia ujemna logarytmiczna wiarygodność modelu:
$$\text{LogLoss} = -\frac{1}{n} \sum_{i=1}^{n} \big(y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)\big),$$
gdzie $y_i \in \{0, 1\}$ oznacza etykietę dla obserwacji i.
- **Brier score** - średni błąd kwadratowy pomiędzy prawdziwą etykietą a przewidzianą PD:
$$\text{Brier} = \frac{1}{n} \sum_{i=1}^{n} (\hat{p}_i - y_i)^2.$$
- **Overfitting (Train–Test)** - różnica pomiędzy AUC na zbiorze uczącym i testowym:
$$\Delta\text{AUC} = \text{AUC}_{\text{train}} - \text{AUC}_{\text{test}}.$$
Duża dodatnia wartość ΔAUC sugeruje przeuczenie modelu.

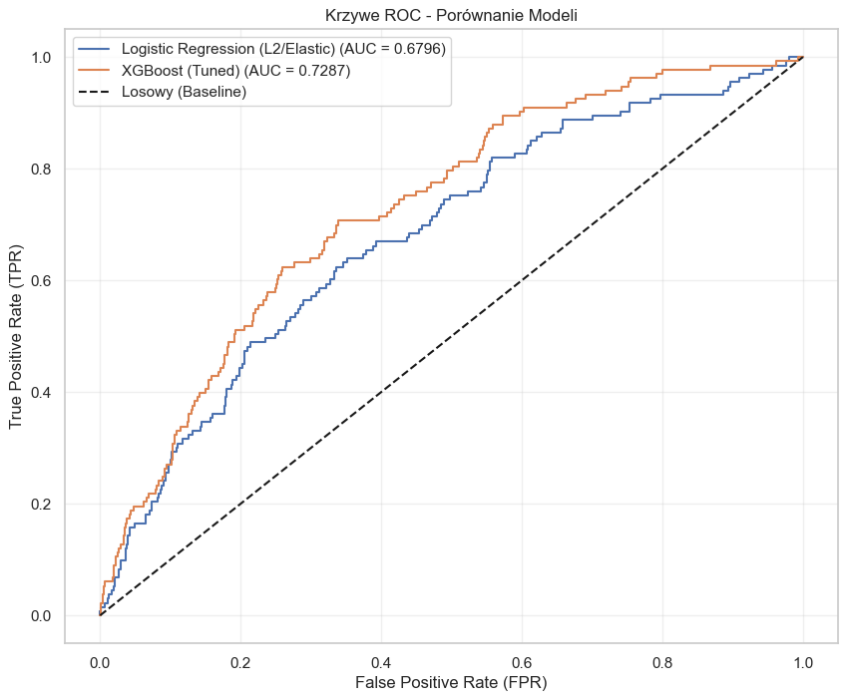

Rysunek 1: Krzywe ROC dla modeli regresji logistycznej oraz XGBoost na zbiorze testowym.

Model	AUC (Test)	AUC (Train)	Gini (Test)	KS Stat	PR-AUC	Log-Loss	Brier Score	Overfitting
Logit	0.679584	0.745567	0.359167	0.287685	0.265488	0.626073	0.215240	0.065983
XGBoost	0.728735	0.897134	0.457470	0.367784	0.308570	0.379143	0.116059	0.168399

W powyższej tabeli przedsawiono dokładnie wszystkie potrzebne metryki dla obu modeli:

Zarówno regresja logistyczna, jak i XGBoost osiągają AUC istotnie powyżej modelu losowego (AUC = 0,5). Model XGBoost charakteryzuje się wyraźnie lepszą zdolnością dyskryminacyjną ($\text{AUC}_{\text{test}} \approx 0{,}736$, Gini $\approx 0{,}47$, KS $\approx 0{,}37$) oraz niższym błędem Brier w porównaniu z regresją logistyczną. Jednocześnie różnica pomiędzy AUC na zbiorze uczącym i testowym jest dla XGBoosta znacznie większa ($\Delta\text{AUC} \approx 0{,}22$) niż dla regresji logistycznej ($\Delta\text{AUC} \approx 0{,}04$), co wskazuje na silniejsze przeuczenie modelu drzewiastego. Regresja logistyczna daje gorszą separację klas, ale jest bardziej stabilna i prostsza do interpretacji. W dalszej części raportu model ten traktujemy jako model referencyjny (interpretable benchmark), natomiast XGBoost jako model typu *black-box* o wyższej skuteczności predykcyjnej kosztem większej złożoności i podatności na overfitting.

7 Interpretowalność modeli

W projektach scoringowych, oprócz wysokiej skuteczności predykcyjnej, kluczowe jest rozumienie mechanizmów podejmowania decyzji przez model oraz ocena zgodności kierunków wpływu cech ze zdrową logiką biznesową. W tym celu przeprowadzono analizę interpretowalności dla dwóch modeli. Analiza obejmuje zarówno interpretację globalną, jak i lokalną, a także ocenę stabilności wpływów cech.

7.1 Interpretowalność globalna modelu regresji logistycznej

Model regresji logistycznej posiada strukturę liniową w przestrzeni logitów, dzięki czemu można wprost odczytywać kierunek i siłę wpływu zmiennych na log-odds zdarzenia (defaultu). Współczynniki modelu zostały wystandaryzowane, co umożliwia bezpośrednie porównywanie względnej siły wpływu cech o różnych skalach.

7.2 Znaki i wielkości współczynników

Tabela 1: Najważniejsze współczynniki regresji logistycznej

Zmienna (feature)	**Współczynnik (coef)**	**Odds ratio**
wsk_ROE	-0.2758	0.759
wsk_zadluzenie_kap_wlasnego	0.2161	1.241
wsk_rent_operacyjna_aktywow	0.2019	1.224
wsk_zysk_op_zobowiazania	-0.1885	0.828
Rozliczenia_miedzyokresowe_b	0.1476	1.159
wsk_ROA	-0.1458	0.864
wsk_pokrycia_odsetek_zyskiem	-0.1385	0.871
wsk_kapital_do_aktywa	-0.1243	0.883
wsk_marza_brutto_1	-0.1203	0.887
dotacje	-0.1182	0.889

W celu poprawnej interpretacji modelu regresji logistycznej przeanalizowano współczynniki regresji na poziomie zmiennych bazowych, tj. po połączeniu wszystkich kolumn wynikających z kodowania one-hot oraz wskaźników braków. Każdej zmiennej przypisano ten współczynnik, który miał największą wartość bezwzględną, aby odzwierciedlić jej rzeczywisty wpływ na model.
Dla każdej cechy obliczono również odds ratio, które przekształca współczynnik log-odds do bardziej intuicyjnej postaci procentowej zmiany szans wystąpienia defaultu przy wzroście danej cechy o 1 jednostkę (po standaryzacji). Na tej podstawie określono także kierunek wpływu — czy zmienna zwiększa, czy zmniejsza ryzyko kredytowe.
Tabela poniżej przedstawia piętnaście najistotniejszych zmiennych w modelu wraz z kierunkiem i siłą ich wpływu na prawdopodobieństwo defaultu.

Tabela 2: Najważniejsze zmienne w modelu regresji logistycznej wraz z interpretacją wpływu

Zmienna bazowa	**Współczynnik (coef)**	**Odds ratio**	**Zmiana szans defaultu**	**Kierunek wpływu**
wsk_ROE	-0.2758	0.759	-24.1%	zmniejsza ryzyko
wsk_zadluzenie_kap_wlasnego	0.2161	1.241	+24.1%	zwiększa ryzyko
wsk_rent_operacyjna_aktywow	0.2019	1.224	+22.4%	zwiększa ryzyko
wsk_zysk_op_zobowiazania	-0.1885	0.828	-17.2%	zmniejsza ryzyko
Rozliczenia_miedzyokresowe_biezace	0.1476	1.159	+15.9%	zwiększa ryzyko
wsk_ROA	-0.1458	0.864	-13.6%	zmniejsza ryzyko
wsk_pokrycia_odsetek_zyskiem	-0.1385	0.871	-12.9%	zmniejsza ryzyko
wsk_kapital_do_aktywa	-0.1243	0.883	-11.7%	zmniejsza ryzyko
wsk_marza_brutto_1	-0.1203	0.887	-11.3%	zmniejsza ryzyko
dotacje	-0.1182	0.889	-11.1%	zmniejsza ryzyko

7.3 Profilowanie cech: PDP i ICE

Aby ocenić nieliniowe zależności i punkty nasycenia, wykonano krzywe PDP (Partial Dependence Plots) oraz ICE (Individual Conditional Expectation). Krzywe PDP pokazują średni wpływ danej zmiennej na predykcję, natomiast ICE ujawniają różnice pomiędzy poszczególnymi obserwacjami.
Uzyskane wykresy potwierdzają, że kierunek wpływu kluczowych zmiennych jest monotoniczny, co jest zgodne z założeniami scoringowymi i wspiera interpretowalność modelu.

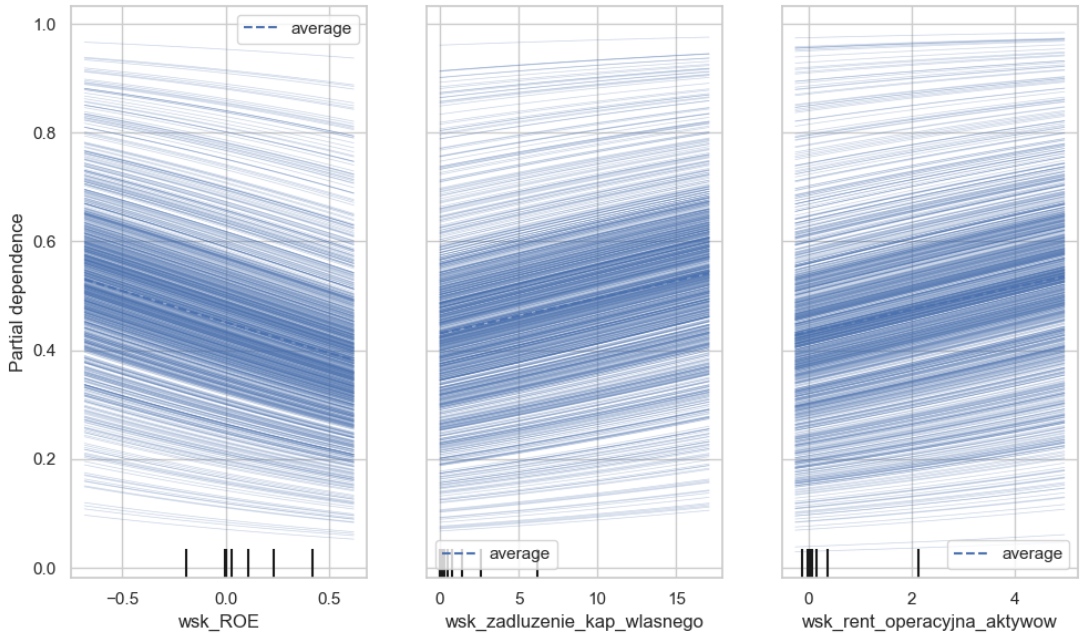

Rysunek 2: Przykładowe krzywe PDP dla modelu regresji logistycznej.

7.4 Interpretowalność lokalna modelu regresji logistycznej

Aby wyjaśnić predykcje modelu regresji logistycznej na poziomie pojedynczych klientów, dokonano analizy lokalnej opartej na dekompozycji wartości logitu. W tym celu przygotowano funkcję, która dla wybranej obserwacji odtwarza pełen łańcuch przetwarzania, następnie oblicza zakodowane i przeskalowane wartości cech, a w kolejnym kroku mnoży je przez odpowiadające im współczynniki modelu. Wynikowy logit można zatem zapisać jako sumę wkładów poszczególnych cech:

$$\text{logit}(x) = \beta_0 + \sum_i z_i \beta_i,$$

gdzie z_i oznacza wartość cechy po pełnym preprocessingu, a β_i — jej współczynnik. Tak uzyskane *wkłady cech* pozwalają dokładnie określić, które zmienne oraz w jakim stopniu zwiększają lub zmniejszają przewidywane prawdopodobieństwo defaultu dla konkretnego klienta.

Dla celów analitycznych wybrano dwie obserwacje: klienta z defaultem oraz klienta dobrego. Dla każdego z nich zaprezentowano ranking dziesięciu najważniejszych zmiennych na podstawie bezwzględnej wartości wkładu do logitu. W przypadku klienta z defaultem dominują zmienne podnoszące ryzyko, takie jak *wsk_rent_operacyjna_aktywow*

czy *wsk_zysk_operacyjny_zob_2*, których wkłady są dodatnie i w istotny sposób przesuwają logit w kierunku wyższej wartości PD. Jednocześnie pewne zmienne, takie jak *wsk_kapital_do_aktywa*, działają ochronnie, obniżając logit i tym samym zmniejszając ryzyko przewidywane przez model.
Dla klienta dobrego obserwujemy odwrotny wzorzec - największe wkłady mają cechy, które obniżają ryzyko (wkłady ujemne), takie jak *wsk_ROA*, czy *wsk_ROE*.

7.5 Interpretowalność globalna modelu XGBoost

Model XGBoost, mimo że uzyskał najwyższą skuteczność predykcyjną, jest modelem trudniejszym do bezpośredniej interpretacji, ze względu na swoją nieliniową i addytywno-drzewiastą strukturę. Do analizy wpływu cech wykorzystano metody wyjaśnialności model-agnostic, w szczególności SHAP).

7.6 Ważność cech: SHAP summary

Globalna analiza SHAP wskazuje, które zmienne mają największy wpływ na finalne predykcje modelu. Efekt kierunkowy (kolor) pozwala dodatkowo ocenić, czy wysokie wartości danej cechy zwiększają, czy zmniejszają ryzyko defaultu.

Uzyskane wyniki wskazują, że model XGBoost wykorzystuje podobne grupy cech jak model logistyczny, lecz dodatkowo wychwytuje interakcje i nieliniowe zależności, niedostępne dla regresji liniowej.

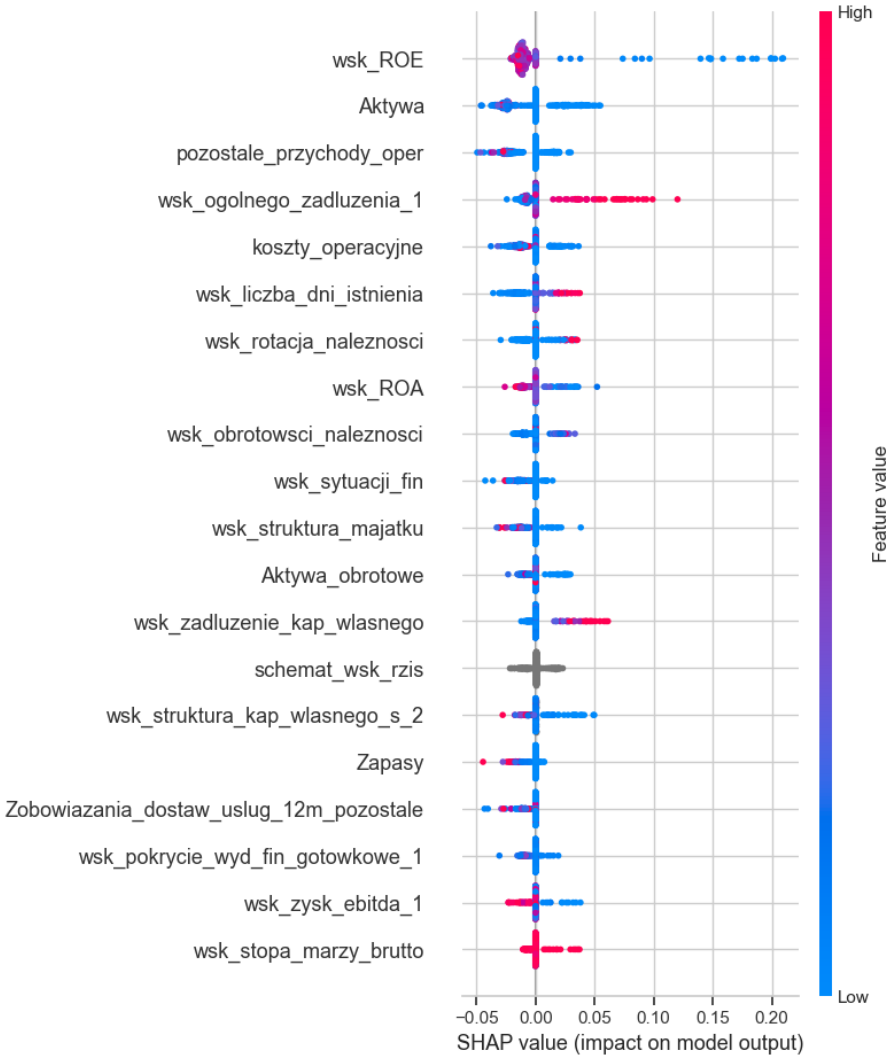

Rysunek 3: Ważność cech w modelu XGBoost (SHAP na próbce zbioru treningowego).

7.7 Krzywe zależności SHAP

Dla najważniejszych cech wykonano wykresy zależności SHAP, które ujawniają nieliniowe relacje (np. efekty progowe, regiony nasycenia) oraz interakcje pomiędzy dwiema zmiennymi.

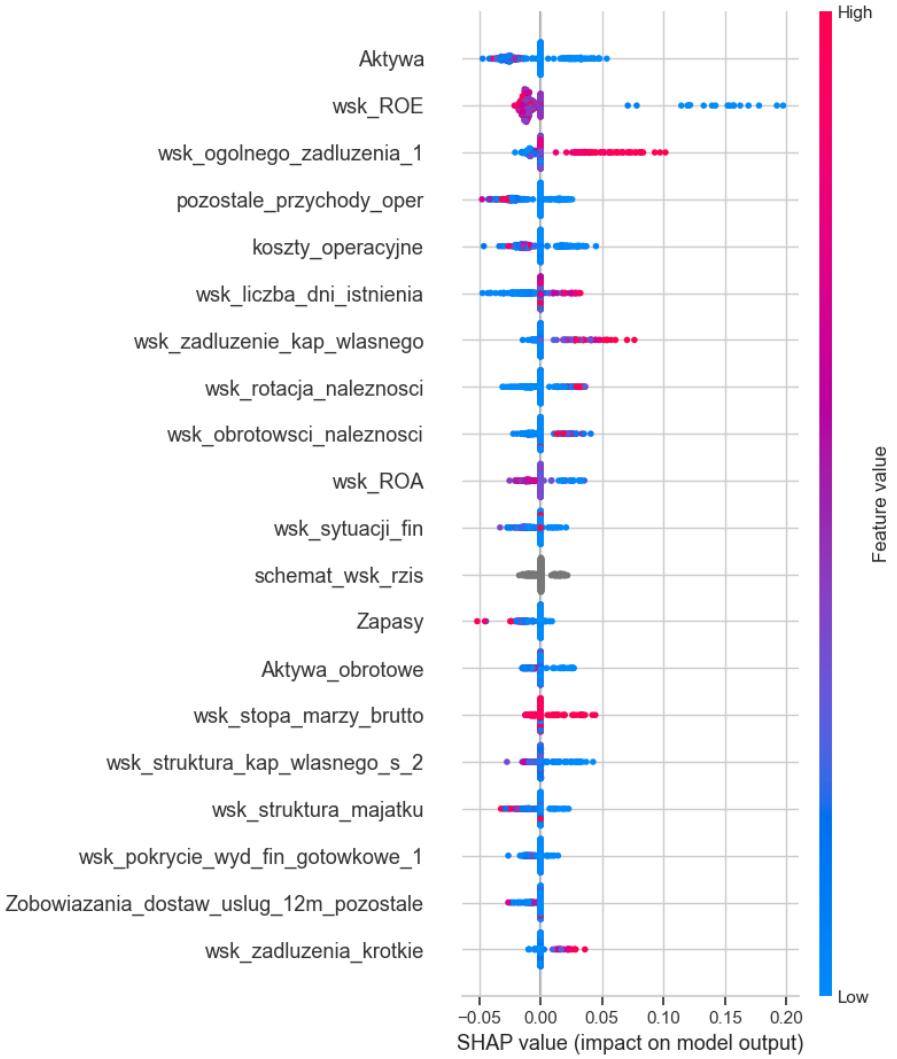

Rysunek 4: Ważność cech w modelu XGBoost (SHAP na próbce zbioru testowego).

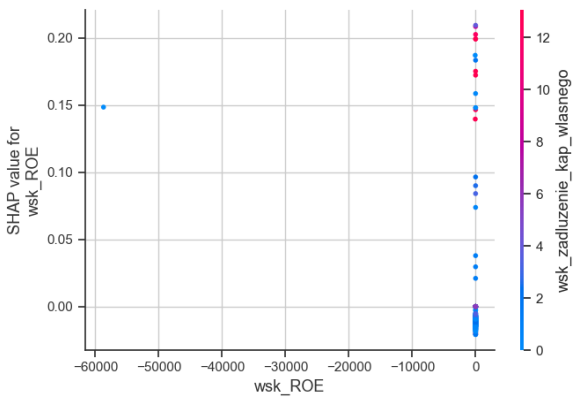

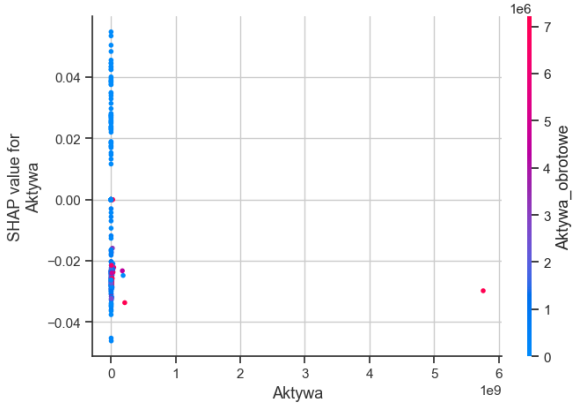

7.8 Interpretowalność lokalna modelu XGBoost

Model XGBoost, ze względu na swoją nieliniową strukturę i mechanizm losowego budowania drzew, wymaga metod wyjaśnialności typu model-agnostic. W projekcie zastosowano wartości SHAP, które pozwalają rozłożyć indywidualną predykcję na sumę wkładów wszystkich cech, analogicznie do dekompozycji wyniku w regresji logistycznej, lecz z

uwzględnieniem pełnej nieliniowości i interakcji pomiędzy zmiennymi.
Do interpretacji lokalnej wybrano dwie obserwacje ze zbioru testowego: klienta z defaultem oraz klienta dobrego. Dla każdej z nich wyznaczono wartości SHAP za pomocą klasycznego *Kernel Explainer*, a następnie przedstawiono je na wykresach typu *waterfall*.

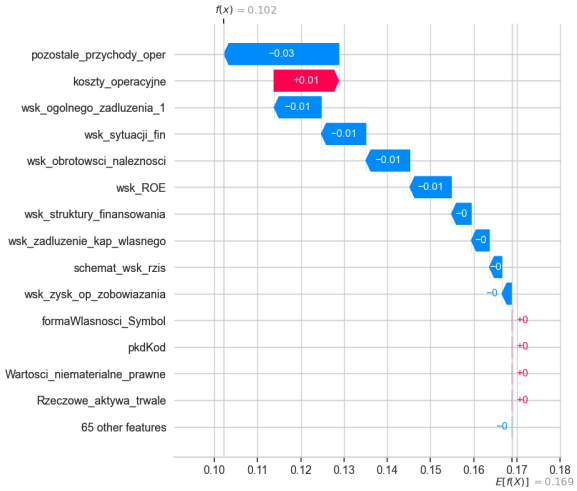

Rysunek 5: Klient z defaultem

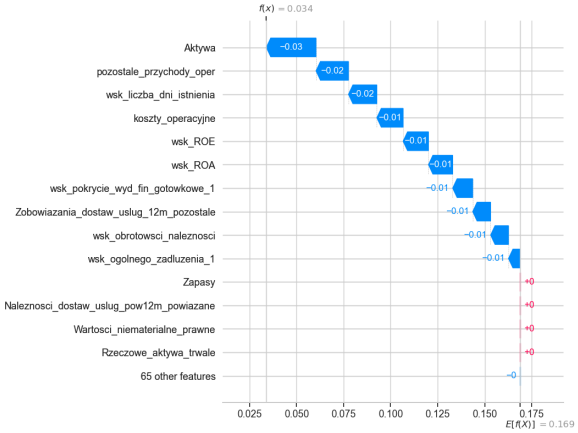

Rysunek 6: Klient bez defaultu

W przypadku klienta z defaultem dominują dodatnie wkłady cech, które przesuwają predykcję w stronę wyższego PD. Największy wpływ mają zmienne finansowe związane z zadłużeniem, strukturą kapitału oraz przepływami operacyjnymi, co jest zgodne z zachowaniem globalnym modelu oraz intuicją ekonomiczną. U klienta dobrego obserwujemy odwrotny wzorzec: kluczowe cechy mają wkłady ujemne, obniżające predykcję i przesuwające wynik modelu poniżej linii referencyjnej.

7.9 Porównanie interpretowalności modeli

Regresja logistyczna zapewnia pełną, bezpośrednią interpretację parametrów oraz transparentność zgodną z wymogami modeli scoringowych. Model XGBoost, mimo lepszych wyników predykcyjnych, wymaga zastosowania narzędzi SHAP, aby uzyskać równoważny poziom zrozumiałości.

Wnioski:

- oba modele wykorzystują podobne kluczowe cechy, co zwiększa wiarygodność wyników,
- XGBoost uchwytuje bardziej złożone zależności (interakcje, nieliniowości),
- regresja logistyczna pozostaje prostsza i bardziej transparentna, co jest kluczowe w zastosowaniach regulacyjnych,
- modele są spójne kierunkowo, co zwiększa ich interpretowalność i akceptowalność .

8 Kalibracja

8.1 Kalibracja prawdopodobieństw dla modelu XGBoost

Model XGBoost dostarcza predykcje w postaci prawdopodobieństw $\hat{p}_i = P(Y_i = 1 \mid X_i)$, które nie muszą być dobrze skalibrowane (tzn. średnia przewidywana PD w danym przedziale nie musi odpowiadać rzeczywistej częstości defaultów). Dlatego przeprowadzono osobną procedurę kalibracji prawdopodobieństw.

Schemat walidacji dla kalibracji

Gotowy, dostrojony model XGBoost (pipeline `final_xgb_pipe`) został najpierw nauczony na zbiorze uczącym X_{trainval}. Następnie zbiór testowy X_{test} podzielono na dwie części:

- zbiór *kalibracyjny* $(X_{\text{calib}}, y_{\text{calib}})$, na którym uczone są modele kalibracyjne,
- ostateczny zbiór testowy $(X_{\text{test-final}}, y_{\text{test-final}})$, który służy wyłącznie do oceny jakości kalibracji.

Podział wykonano funkcją `train_test_split` z opcją `stratify=y_test`, dzięki czemu zachowano ten sam udział defaultów w obu podzbiorach.

Metody kalibracji: isotonic, sigmoid, CIT

Na podstawie surowych predykcji XGBoosta zastosowano trzy standardowe metody kalibracji:

1. **Isotonic regression** – nieliniowa, monotoniczna regresja pomiędzy surowym prawdopodobieństwem a faktyczną częstością defaultu. W implementacji wykorzystano klasę `CalibratedClassifierCV` z parametrem `method='isotonic'` i `cv='prefit'`.
2. **Platt scaling (sigmoid)** – dopasowanie funkcji logistycznej do surowych logitów, również poprzez `CalibratedClassifierCV` z parametrem `method='sigmoid'`.
3. **Calibration-in-the-large (CIT)** – osobny model regresji logistycznej dopasowany do zależności
$$y_{\text{calib}} \sim a + b \cdot (\hat{p}_{\text{raw}}),$$
gdzie $(p) = \log\left(\frac{p}{1-p}\right)$. Estymowane parametry a (intercept) oraz b (slope) służą do przeskalowania logitów na zbiorze testowym:
$$\hat{p}_{\text{CIT}} = \sigma\big(a + b \cdot (\hat{p}_{\text{raw}})\big),$$
gdzie $\sigma(\cdot)$ oznacza funkcję sigmoidalną.

Dla wszystkich wariantów policzono Brier score oraz AUC na zbiorze $X_{\text{test-final}}$, a dla surowego modelu, wersji isotonic i sigmoid również średni błąd kalibracji (ECE). Wyniki zestawiono w tabeli poniżej:

Tabela 3: Porównanie jakości kalibracji dla XGBoosta na zbiorze $X_{\text{test-final}}$.

Wariant modelu	Brier	AUC	ECE
XGBoost surowy	0.116	0.736	0.043
XGBoost + isotonic	0.115	0.740	0.027
XGBoost + sigmoid	0.117	0.736	0.057
XGBoost + CIT (intercept+slope)	0.115	0.751	–

Na poniższym rysunku pokazano krzywe kalibracji (reliability diagrams) dla trzech wybranych wariantów: modelu surowego, po kalibracji isotonic oraz po Platt scaling. Widzimy, że kalibracja isotonic istotnie zmniejsza odchylenia od prostej idealnej kalibracji, co potwierdza niższy Brier score oraz niższy ECE (średni błąd kalibracji).

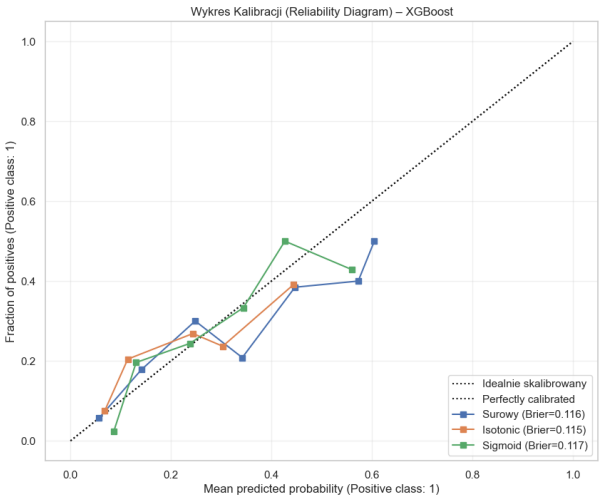

Rysunek 7: Wykresy kalibracji (reliability diagrams) dla modelu XGBoost

Kalibracja-in-the-large do 4% PD

Dodatkowym wymaganiem była kalibracja *globalnej* tendencji centralnej tak, aby średnie przewidywane prawdopodobieństwo defaultu na zbiorze testowym wynosiło 4%. W tym celu wykorzystano predykcje po kalibracji isotonic $\hat{p}_{\text{iso}}$ i dokonano jednolitego przesunięcia logitów:

$$\hat{p}_{4\%} = \sigma\big((\hat{p}_{\text{iso}}) + \delta\big),$$

gdzie stała δ została dobrana numerycznie tak, aby

$$\frac{1}{n}\sum_{i=1}^{n} \hat{p}_{4\%,i} \approx 0.04.$$

W praktyce średnia PD spadła z ok. 0.142 (po isotonic) do 0.040 (po zastosowaniu przesunięcia $\delta \approx -1.48$).

Jakość tak „wymuszonej" kalibracji podsumowano poniżej:

- przed 4% (XGBoost + isotonic): Brier $\approx$ 0.114, AUC $\approx$ 0.744, ECE $\approx$ 2.7%,
- po kalibracji do 4%: Brier $\approx$ 0.130, AUC $\approx$ 0.740, ECE $\approx$ 11.8%.

Na rysunku poniżej przedstawiono porównanie krzywych kalibracji przed i po dostrojeniu do 4% PD. Widać, że choć średnia PD została doprowadzona do wymaganego poziomu, lokalna kalibracja w poszczególnych przedziałach ulega pogorszeniu (krzywa dla wariantu 4% odchyla się od prostej idealnej znacznie bardziej niż krzywa bazowa).

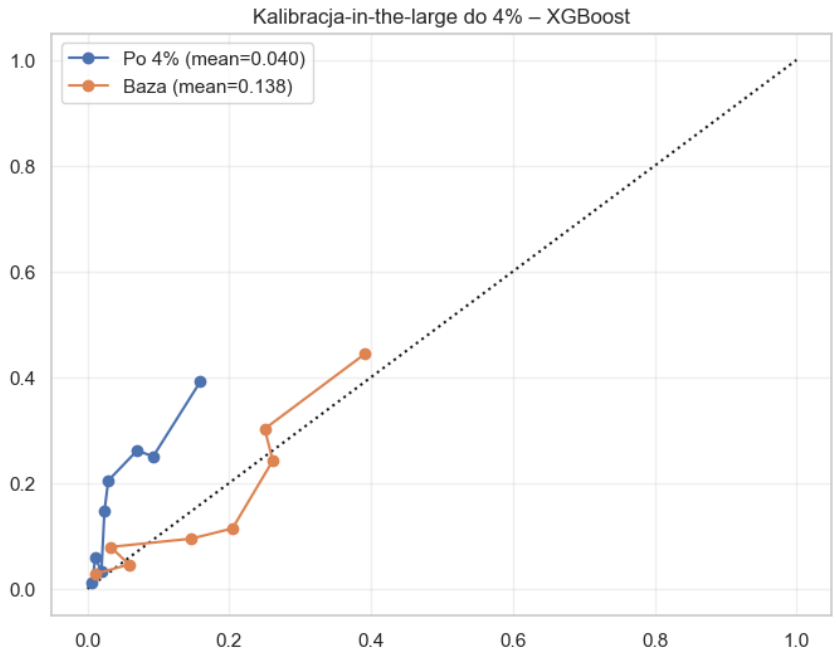

Rysunek 8: Kalibracja-in-the-large do poziomu 4% PD (porównanie wersji bazowej po isotonic i po przesunięciu logitów).

Podsumowując, najlepszą lokalną kalibrację (najniższy Brier score i ECE) uzyskujemy dla XGBoosta po kalibracji isotonic. Dodatkowy krok dostrojenia do 4% średniej PD spełnia wymaganie biznesowe dotyczące poziomu portfelowego, ale odbywa się kosztem pogorszenia lokalnej kalibracji w poszczególnych przedziałach PD. W dalszych analizach

przy interpretacji modelu używamy jednocześnie wariantu dobrze skalibrowanego (isotonic) oraz wariantu dopasowanego do 4% PD, podkreślając kompromis między kalibracją globalną i lokalną.

8.2 Kalibracja prawdopodobieństw dla modelu regresji logistycznej

Poniżej przedstawiono krzywe kalibracji (reliability curves) dla modelu regresji logistycznej: model bazowy, model skalibrowany metodą Platta z poprawką calibration-in-the-large (CIL) oraz model z kalibracją izotoniczną. Linia przerywana oznacza idealną kalibrację ($y = x$), czyli sytuację, w której przewidziane prawdopodobieństwa dokładnie odzwierciedlają rzeczywistą częstość defaultów.

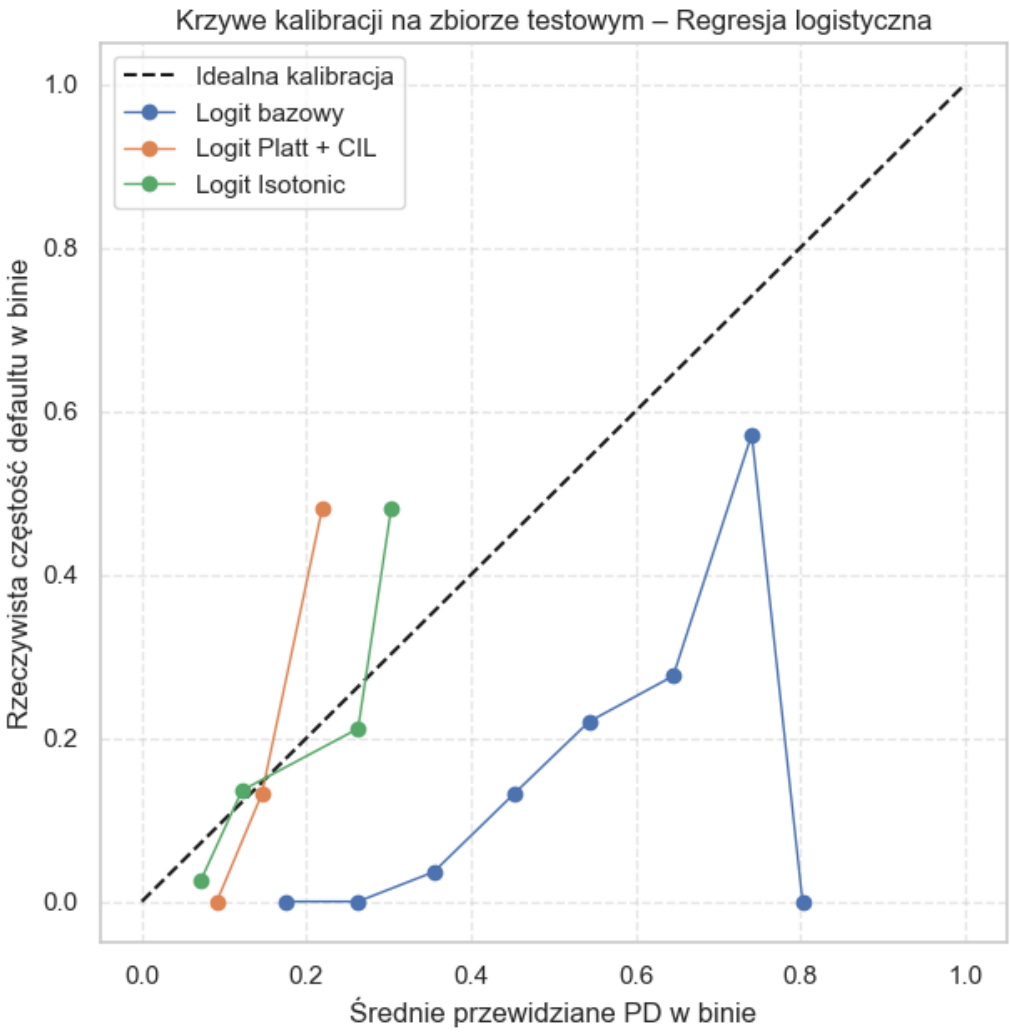

Wykres pokazuje, że model bazowy jest wyraźnie rozkalibrowany. Zastosowanie Platt + CIL znacząco poprawia dopasowanie do linii idealnej, natomiast kalibracja izotoniczna daje najbardziej płynną i stabilną krzywą. Obie metody kalibracyjne sprawiają, że przewidywane PD stają się znacznie bardziej wiarygodne.

9 Progi decyzyjne i mapowanie PD na ratingi

9.1 Dobór progu decyzyjnego na podstawie funkcji kosztu

Po skalibrowaniu modelu do średniej tendencji centralnej PD $\approx 4\%$ konieczne jest wyznaczenie progu decyzyjnego, powyżej którego wniosek kredytowy jest odrzucany (predykcja klasy `1` - default), a poniżej którego wniosek jest akceptowany (predykcja klasy `0`).
Zastosowano prosty, ale interpretowalne podejście oparte na **funkcji kosztu**, w której różne typy błędów klasyfikacji mają różne wagi. Dla zadanego progu $t \in [0, 1]$ predykcje binarne są definiowane jako

$$\hat{y}(t) = \begin{cases} 1 & \text{jeśli PD} \geq t, \\ 0 & \text{w przeciwnym wypadku.} \end{cases}$$

Na tej podstawie obliczana jest macierz pomyłek (TN, FP, FN, TP), a łączny koszt decyzji definiujemy jako:

$$\text{Cost}(t) = c_{\text{FP}} \cdot \text{FP}(t) + c_{\text{FN}} \cdot \text{FN}(t) + c_{\text{TP}} \cdot \text{TP}(t) + c_{\text{TN}} \cdot \text{TN}(t),$$

gdzie parametry c_{FP} i c_{FN} określają względny koszt błędnej akceptacji klienta (fałszywie negatywna decyzja o braku defaultu) oraz błędnego odrzucenia klienta dobrej jakości (fałszywy pozytyw).
W przeprowadzonych eksperymentach przyjęto relację:

$$c_{\text{FP}} = 1, \quad c_{\text{FN}} = 5, \quad c_{\text{TP}} = 0, \quad c_{\text{TN}} = 0,$$

co odzwierciedla fakt, że koszt udzielenia kredytu klientowi, który zbankrutuje (FN), jest wielokrotnie wyższy niż koszt odrzucenia klienta, który w rzeczywistości spłaciłby zobowiązanie (FP). Następnie, dla siatki progów t (np. 200 równomiernie rozłożonych wartości w $[0, 1]$) policzono wartość funkcji kosztu i wybrano próg minimalizujący łączny koszt.
Na rysunku przedstawiono przebieg krzywej kosztu w funkcji progu oraz zaznaczono wybrany próg $t^\star$:

9.2 Macierz pomyłek i metryki dla optymalnego progu

Dla optymalnego progu $t^\star = 0.0352$ wyznaczono finalne predykcje binarne oraz odpowiadającą im macierz pomyłek:

$$\begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix},$$

a także kluczowe metryki klasyfikacyjne, które wyniosły odpowiednio:

- **Precision** (jaki odsetek obserwacji zaklasyfikowanych jako default faktycznie jest defaultem) = 0.25,
- **Recall (TPR)** (jaka część rzeczywistych defaultów została wykryta przez model) = 0.712,
- **F1-score** (harmoniczna średnia precision i recall) = 0.37,

Wyniki pokazują kompromis pomiędzy maksymalizacją wykrywania defaultów (wysoki recall) a ograniczaniem liczby błędnych odrzuceń klientów dobrych (niski FPR), przy jednoczesnym uwzględnieniu zadanej funkcji kosztu.

9.3 Mapowanie skalibrowanej PD na ratingi

Kolejnym krokiem było przejście od ciągłej predykcji prawdopodobieństwa defaultu do dyskretnej skali ratingowej, która jest bardziej użyteczna z punktu widzenia biznesu i komunikacji z interesariuszami. W tym celu zdefiniowano przedziały PD odpowiadające klasom ratingowym:

$$[0.00, 0.01) \to \text{AAA}, \quad [0.01, 0.02) \to \text{AA}, \quad [0.02, 0.04) \to \text{A}, \quad [0.04, 0.07) \to \text{BBB},$$

$$[0.07, 0.10) \to \text{BB}, \quad [0.10, 0.20) \to \text{B}, \quad [0.20, 1.01) \to \text{CCC}.$$

Dla każdej obserwacji na zbiorze testowym skalibrowana PD została przypisana do jednej z powyższych klas za pomocą funkcji `pd.cut`. Następnie zbudowano tabelę ratingową, w której dla każdej klasy ratingowej policzono:

- liczność n,
- obserwowany współczynnik defaultu (empiryczny default rate),
- średnią predykowaną PD w danej klasie (mean PD).

Rating	n	Default rate	Mean PD
AAA	111	0.009009	0.007564
AA	45	0.044444	0.014480
A	106	0.150943	0.022517
BBB	86	0.197674	0.046494
BB	39	0.205128	0.070346
B	58	0.327586	0.108788
CCC	5	0.600000	0.214089

Poniższy wykres zależności średniej PD i obserwowanego default rate od klasy ratingowej potwierdza wymaganą **monotoniczność** (ratingi gorsze mają wyższą PD i wyższy obserwowany default rate), co jest kluczowe dla poprawności skali ratingowej. Najlepsze ratingi (AAA, AA, A) charakteryzują się niskim obserwowanym ryzykiem, podczas gdy klasy BB, B oraz CCC skupiają obserwacje o najwyższej częstości defaultów.

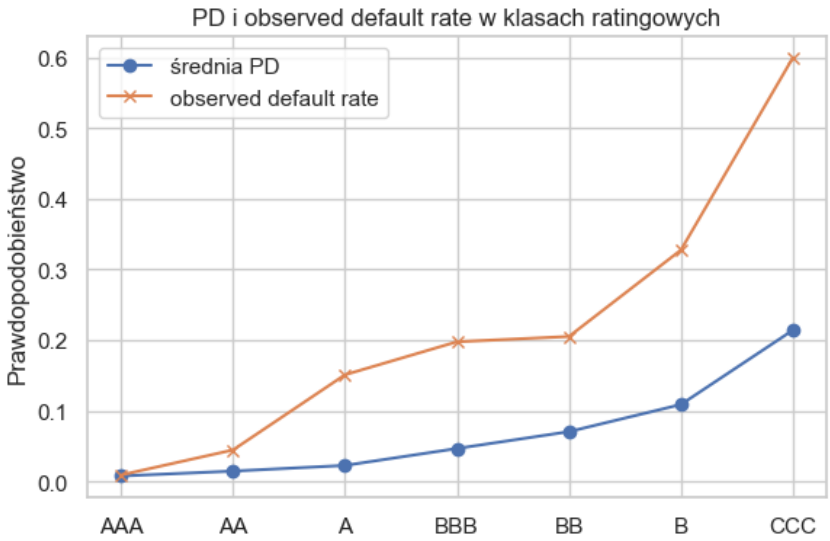

9.4 Interpretacja biznesowa progu i ratingów

Dobór optymalnego progu decyzyjnego po kalibracji modelu do średniej PD na poziomie 4% umożliwia przełożenie predykcji modelu na realne decyzje kredytowe. Wybrany próg odzwierciedla kompromis pomiędzy ryzykiem udzielenia kredytu klientowi o wysokim prawdopodobieństwie defaultu a kosztem odrzucenia klientów, którzy mogliby bezproblemowo spłacić swoje zobowiązanie. Zastosowana funkcja kosztu, w której błąd fałszywie negatywny (FN — zaakceptowanie klienta ryzykownego) jest pięciokrotnie droższy niż fałszywie pozytywny (FP — odrzucenie klienta dobrego), skutkuje konserwatywną strategią akceptacji i wyraźnie zmniejsza ryzyko strat portfelowych. Dodatkowo zmapowanie skalibrowanych PD na siedmiostopniową skalę ratingową (od AAA do CCC) pozwala uporządkować klientów według poziomu ryzyka oraz tworzy przejrzystą strukturę decyzyjną, zarówno dla procesów kredytowych, jak i dla komunikacji z interesariuszami. Analiza tabeli ratingowej potwierdza monotoniczność — gorszym ratingom odpowiada wyższa średnia PD oraz wyższy obserwowany default rate — co oznacza, że system ratingowy jest spójny i zgodny z intuicją ryzyka, a jednocześnie gotowy do wykorzystania w praktyce biznesowej

10 Wnioski i podsumowanie

Przeprowadzone analizy pokazują, że oba modele — regresja logistyczna i XGBoost — skutecznie przewidują ryzyko defaultu, jednak pełnią różne funkcje w procesie oceny ryzyka. Model logistyczny cechuje się wysoką przejrzystością, stabilnością i łatwością interpretacji, co czyni go idealnym kandydatem na model referencyjny, zgodny z wymaganiami nadzorczymi i biznesowymi. Z kolei XGBoost oferuje wyższą skuteczność predykcyjną (AUC, log-loss, KS), kosztem mniejszej transparentności, którą uzupełniają techniki SHAP zapewniające wgląd w globalny i lokalny wpływ cech. Proces kalibracji probabilistycznej poprawił jakość predykcji probabilistycznych oraz umożliwił stworzenie spójnej i monotonicznej skali ratingowej. Integracja tych elementów — predykcji, interpretowalności, kalibracji i ratingów — pozwoliła zbudować kompletny, praktyczny i zgodny z dobrymi praktykami scoringowymi system oceny ryzyka, który może być realnie wykorzystywany w procesach decyzyjnych i monitoringu portfela.